



Πολυτεχνείο Κρήτης

Σχολή Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών

Ταξινόμηση Κυρίαρχων Γραφημάτων Λειτουργικής Συνδεσιμότητας από Ήπιες Τραυματικές Εγκεφαλικές Κακώσεις με χρήση των Δικτύων Kolmogorov-Arnold (KAN)

Ελένη Σταυροπούλου

Διπλωματική Εργασία | 2026

Επιτροπή:

Καθ. Μιχαήλ Ζερβάκης

Καθ. Αθανάσιος Λιάβας

Καθ. Διονύσιος Χριστόπουλος

Περιεχόμενα

- Κίνητρα και Στόχοι
- Θεωρητικό Υπόβαθρο — mTBI, MEG, dFC, KAN
- Προηγούμενη Μελέτη — Source Reconstuction, dFC Graph Extraction, CFC
- Μεθοδολογία — Laplacian, Neural Gas, Εξαγωγή Χαρακτηριστικών, KAN, Πρωτόκολλο Αξιολόγησης
- Αποτελέσματα — Απόδοση, Σημαντικότητα Χαρακτηριστικών, Σύγκριση
- Συζήτηση, Περιορισμοί & Μελλοντική Έρευνα

Κίνητρα & Στόχοι

Γιατί ΚΑΝ δίκτυα;

Κίνητρα & Στόχοι

Το Πρόβλημα

mTBI ~90% όλων των TBIs

CT/MRI δεν το εντοπίζουν

Υποκειμενική διάγνωση

Ανάγκη αντικειμενικών βιοδεικτών

Η Προσέγγιση

MEG + dFC

Neural Gas (k=2)

10 χαρακτηριστικά

KAN ταξινομητής

Οι Στόχοι

Ακρίβεια στην ταξινόμηση

Anchoring ετικετών

Εφαρμογή KAN σε νευροαπεικόνιση


Ερμηνευσιμότητα και Διαφάνεια

Θεωρητικό Υπόβαθρο

mTBI · MEG · dFC · KAN

Δομή Εγκεφάλου & mTBI

Brain Functions by Lobe



- 4 λοβοί με διακριτές λειτουργίες, διασυνδεδεμένοι μέσω λευκής ουσίας
- Επικοινωνία μέσω συγχρονισμού ταλαντωτικής δραστηριότητας (δ , θ , α , β , γ)

mTBI

Επιδημιολογία

Αμνησία <24h | ~20% επίμονα συμπτώματα

Μηχανισμός

Diffuse Axonal Injury → βλάβη white matter tracts

CT/MRI


Μικροσκοπική και διάχυτη βλάβη → απεικόνιση ανεπαρκής

MEG

Υψηλή χρονική ανάλυση (ms) → ανίχνευση διακυμάνσεων συνδεσιμότητας

Λευκή ουσία = φυσικό μέσο επικοινωνίας → κύρια περιοχή βλάβης στο mTBI

Magnetoencephalography (MEG) & Dynamic Functional Connectivity (dFC)




MEG

- Μετρά μαγνητικά πεδία $\sim 10^{-13}$ Tesla
- Υψηλή χρονική ανάλυση (ms)
- Δεν παραμορφώνεται από κρανίο/δέρμα (vs EEG)
- Άμεση μέτρηση νευρικής δραστηριότητας (vs fMRI)
- Ευαίσθητη σε διαταραχές λειτουργικής συνδεσιμότητας

dFC

- sliding windows $\rightarrow$ time-varying connectivity graphs
- Αποτύπωση διακυμάνσεων εγκεφάλου ανά δευτερόλεπτο
- Απεικονιστικά:
Κόμβοι = περιοχές εγκεφάλου
Ακμές = ισχύς συγχρονισμού



Θεώρημα Kolmogorov-Arnold & KAN Αρχιτεκτονική

Το Θεώρημα

Κάθε συνεχής συνάρτηση πολλών μεταβλητών f αναπαρίσταται αποκλειστικά ως σύνθεση συνεχών συναρτήσεων μίας μεταβλητής και της πράξης της πρόσθεσης:

$$f(x_1, \dots, x_n) = \sum_{q=1}^{2n+1} \Phi_q \left(\sum_{p=1}^n \varphi_{q,p}(x_p) \right)$$

Ουσιαστικά, η μόνη multivariate πράξη είναι η πρόσθεση.

Ορισμός KAN

Μορφή

$[n_0, n_1, \dots, n_L]$

n_i κόμβοι ανά στρώμα L

Κόμβος

$x_{\{l+1, j\}} = \sum_i \varphi_{\{l, i\}}(x_{\{l, i\}})$

Άθροισμα εισερχόμενων ενεργοποιήσεων

Layer

$\Phi = \{\varphi_{q,p}\}$

Πίνακας learnable συναρτήσεων

Σύνθεση

$KAN(x) = (\Phi_{\{L-1\}} \circ \dots \circ \Phi_0)(x)$

L διαδοχικά layers

Αρχιτεκτονική

2-layer (Θεώρημα)


Kolmogorov & Arnold, 1957

Arbitrary depth & width

Liu et al. (2024) $\rightarrow$ KAN

KAN vs MLP


Multi-Layer Perceptron



MLP

σταθερό σ στους κόμβους · βάρη w στις ακμές · black box

Kolmogorov-Arnold Network



KAN

learnable ϕ στις ακμές · πρόσθεση στους κόμβους · οπτικοποίηση

B-Spline Παραμετροποίηση

Κάθε ενεργοποίηση $\phi(x)$:

$$\phi(x) = w \cdot (b(x) + \text{spline}(x))$$

$$\text{spline}(x) = \sum_i c_i \cdot B_i(x)$$

$$b(x) = \text{SiLU}(x)$$

w : Xavier initialization

c_i : trainable coefficients

$B_i(x)$: B-spline (Basis)

Ορισμοί

Spline: τμηματική πολυωνυμική καμπύλη, που προσεγγίζει ή παρεμβάλλει σημεία μέσω πολυωνυμικών τμημάτων που συνδέονται ομαλά μεταξύ τους.

B-Spline: τμηματική πολυωνυμική συνάρτηση, που αποτελείται από Bezier curves, με τη διαφορά ότι υποστηρίζουν local control.

Πλεονεκτήματα B-Splines

- **Local control**: Αλλάζοντας ένα control point, αλλάζει μόνο το τμήμα της καμπύλης σε αυτό το control point.
- **Superior scaling law**: Σφάλμα $\propto N^{-4}$ (vs N^{-1} για MLP) $\rightarrow$ 4× καλύτερη αποδοτικότητα παραμέτρων

Ιδανικό για μικρά biomedical datasets, επιρρεπή σε overfitting.

Loss Function & Feature Importance

Loss Function

$$\ell_{total} = \ell_{pred} + \lambda(\mu_1 \Sigma |\Phi_i|_1 + \mu_2 \Sigma S(\Phi_i))$$

ℓ_{pred}

Cross-entropy prediction loss

$\lambda \cdot \mu_1 \Sigma |\Phi_i|_1$

L1 regularization: magnitude των ενεργοποιήσεων

$\lambda \cdot \mu_2 \Sigma S(\Phi_i)$

Entropy penalty: μη-ομοιόμορφη κατανομή magnitudes

L1 + Entropy → pruning των μη σημαντικών ακμών

Intrinsic Feature Importance

$$importance(x_p) = \Sigma_i |\varphi_{i,p}|_1$$

- Άθροισμα L1 norm όλων των ενεργοποιήσεων που συνδέονται με την είσοδο x_p
- Δεν χρειάζεται statistical ranking ή κάποια post-hoc μέθοδος

Προηγούμενη Μελέτη

Pipeline Προεπεξεργασίας MEG

3.1 MEG Προεπεξεργασία & Source Reconstruction

Raw MEG

248 κανάλια · ~1017 Hz · 5 min artifact-free

Preprocessing

Band-pass 0.1–100 Hz · Notch 60 Hz · ICA (FieldTrip)

Source Reconstruction

LCMV beamforming · AAL atlas · 90 ROIs

Virtual Sensors

1 high-SNR χρονοσειρά ανά ROI

90 χρονοσειρές/υποκείμενο

Βασικές Επιλογές

ICA Artifact Removal

Ocular & cardiac components αφαιρούνται με kurtosis, skewness & Rényi entropy thresholding

LCMV Beamforming


Atlas-based spatial filtering σε T1 MRI template → υψηλή χωρική ακρίβεια

Intra-ROI Weighting

Virtual sensors με normalized node strength → υψηλότερο SNR από spatial average

Antonakakis et al. (2019, 2020) · Dimitriadis et al. (2018)

3.2 Εξαγωγή & Φιλτράρισμα Γράφων dFC



Βασικές Επιλογές

iPLV αντί PLV

Το φανταστικό μέρος του PLV αγνοεί zero-lag coupling → παράκαμψη τεχνητών συσχετίσεων από volume conduction

Surrogate Analysis


Στατιστικά αυστηρή αφαίρεση τυχαίου θορύβου → μόνο στατιστικά σημαντικές συνδέσεις διατηρούνται

OMST Filtering

Iterative minimum spanning trees → μέγιστη global efficiency σε χαμηλό κόστος συνδεσιμότητας

Antonakakis et al. (2020) · Dimitriadis et al. (2017a, 2017b)

3.3 Cross-Frequency Coupling & Κυρίαρχη Συχνότητα



Βασικές Επιλογές

Phase-to-Amplitude Coupling (PAC)

Η φάση αργής ταλάντωσης διαμορφώνει το πλάτος γρήγορης → ιεραρχικός συντονισμός που διαταράσσεται στο mTBI

Dominant Frequency Identification

Αντί για 8 ανεξάρτητα bands, κρατά μόνο τη ζώνη με την ισχυρότερη πληροφορία ανά ROI ανά βήμα → αυξάνει τις διαφορές μεταξύ ομάδων

Κλινική Αξία

Cross-frequency PAC metrics διακρίνουν mTBI vs υγιείς με υψηλή ακρίβεια

Antonakakis et al. (2016)

Μεθοδολογία

Από Γράφους dFC σε Ταξινόμηση KAN

Εξαγωγή Laplacian ιδιοτιμών

dFC Γράφοι 90×90 ανά subject

1785 στιγμιότυπα

Κανονικοποιημένος Laplacian

$$L = I - D^{-1/2} G D^{-1/2}$$

Εξαγωγή Ιδιοτιμών

$\text{eig}(L) \rightarrow [\lambda_1, \lambda_2, \dots, \lambda_{90}]$ ταξινομημένες σε αύξουσα σειρά

Επανάληψη για 1785 στιγμιότυπα

Διάνυσμα 90 ιδιοτιμών ανά στιγμιότυπο

Πίνακας Ιδιοτιμών 1785 × 90 ανά subject

Συμπαγής φασματική αναπαράσταση

- Κάθε dFC γράφος 90×90 μετατρέπεται σε ένα διάνυσμα 90 ιδιοτιμών που κωδικοποιεί την τοπολογία του δικτύου.
- Αυτή η φασματική αναπαράσταση συμπιέζει δραστικά τη διάσταση (**90×90 → 90**) διατηρώντας τη χρήσιμη πληροφορία.

Αλγόριθμος Neural Gas ($k=2$)

Πίνακας Ιδιοτιμών 1785×90

Αρχικοποίηση Prototypes

Τυχαία επιλογή P_1, P_2 από τα 1785 vectors

Rank-weighted Updates

Ενημέρωση των P_1, P_2 προς το εκάστοτε vector

Εκθετική Αποσβεστική Σύγκλιση

Μείωση learning rate & neighbourhood width

2 Codebook Vectors P_1, P_2 διάστασης 90

Αναπαριστούν τα κυρίαρχα μοτίβα συνδεσιμότητας

- Ο αλγόριθμος Neural Gas κβαντίζει τα 1785 φασματικά διανύσματα σε $k=2$ πρότυπες καταστάσεις.
- $k=2$: σφάλμα παραμόρφωσης $<2\%$ για κάθε υποκείμενο (Antonakakis et al., 2020)
- Λιγότερο ευαίσθητο στην αρχικοποίηση από k -means.

Συμβολική Χρονοσειρά:



State-Label Consistency

- *O Neural Gas αναθέτει τυχαία labels ανά υποκείμενο.*
- *Anchoring στρατηγική βάσει της μέσης ιδιοτιμής Laplace για τα δύο prototypes ανά υποκείμενο.*
- *Low mean eigenvalue $\Rightarrow$ high connectivity. High mean eigenvalue $\Rightarrow$ low connectivity. (Chung and Graham, 1997)*
- **State 1 = υψηλή συνδεσιμότητα**
State 2 = χαμηλή συνδεσιμότητα

Πρόβλημα:

Υποκ. A - State 1
Υψηλή Συνδεσιμότητα

Υποκ. B - State 1
Χαμηλή Συνδεσιμότητα

State 1 $\neq$ State 1 $\rightarrow$ Μη-έγκυρη σύγκριση





Λύση = Anchoring:

Υποκ. A - State 1
Υψηλή Συνδεσιμότητα

Υποκ. B - State 1
Υψηλή Συνδεσιμότητα

State 1 = State 1 για όλα τα υποκείμενα $\checkmark$

State-Label Consistency



- *State 1: συνδεσιμότητα υγιών > συνδεσιμότητα ασθενών, περιορισμένη υπερσυνδεσιμότητα σε ασθενείς (Antonakakis et al., 2016)*
- *State 2: ανομοιογενές μοτίβο συνδεσιμότητας μεταξύ υγιών και ασθενών*

Εξαγωγή Χαρακτηριστικών & Data Balancing

Από τη συμβολική χρονοσειρά εξάγονται τα εξής 10 χαρακτηριστικά:

Χρονικά (Temporal):

TP

OT₁

DT₁

DT₂

- **Transition Probability (TP):** πόσο συχνά αλλάζει κατάσταση ο εγκέφαλος
- **Occupancy Time (OT₁):** ποσοστό χρόνου στην κατάσταση 1
- **Dwell Time (DT₁, DT₂):** μέση διάρκεια παραμονής ανά κατάσταση

Graph-Theoretic:

GE₁

CC₁

CPL₁

GE₂

CC₂


CPL₂

- **Global Efficiency (GE₁, GE₂):** παράλληλη μεταφορά πληροφορίας
- **Clustering Coefficient (CC₁, CC₂):** τοπική τοπολογική ομαδοποίηση
- **Characteristic Path Length (CPL₁, CPL₂):** μέση διαδρομή δικτύου

Λόγω ανισορροπίας των κλάσεων (49 υγιείς + 30 mTBI), έγινε τυχαία υποδειγματοληψία υγιών σε 100 επαναλήψεις και προέκυψε ένα ισορροπημένο dataset **60 υποκειμένων (30/30)**.


KAN Αρχιτεκτονική

- Shallow [$n_feat, 2$], χωρίς hidden layers
- Cubic B-splines συναρτήσεις ϕ ($k=3$), $G=3$ intervals $\rightarrow$ 6 basis functions/activation
- Cross-entropy loss + Adam optimizer
- $\lambda=0.01$ sparsification για pruning των μη σημαντικών ακμών
- 30 training steps




Πρωτόκολλο Αξιολόγησης

- Υιοθετήθηκε πρωτόκολλο αξιολόγησης 2 φάσεων επαναλαμβανόμενο σε 100 ανεξάρτητα runs.
- **Φάση 1 (Stratified 5-fold CV):** Επιλογή βέλτιστου *threshold* τ μεταξύ των $\{0, 0.1, 0.15, 0.2, 0.25, 0.35\}$ για *feature pruning*.
- **Φάση 2 (LOO Testing):** Leave-One-Out σε 12 subjects (held-out test set) για αμερόληπτη εκτίμηση.



Αντιμετώπιση Overfitting



- *Κίνδυνος overfitting λόγω μεγέθους dataset*
- *Λύση: shallow αρχιτεκτονική, sparsification regularization, αυστηρά disjoint splits μεταξύ φάσεων 1 και 2, και 100 τυχαία runs για αξιοπιστία μετρικών απόδοσης*
- *Στην απεικόνιση του Cross Entropy Loss, το train/test gap σταθεροποιείται και καμία από τις καμπύλες δεν αποκλίνει.*

Μετρικές Αξιολόγησης

Accuracy

$$(TP + TN) / (TP + TN + FP + FN)$$

Συνολικό ποσοστό σωστών προβλέψεων

Sensitivity

$$TP / (TP + FN)$$

% αληθών mTBI ασθενών που εντοπίστηκαν

Specificity


$$TN / (TN + FP)$$

% αληθών υγιών που εντοπίστηκαν

AUC-ROC

Area under Sensitivity vs (1-Specificity) curve

Διαχωριστική ικανότητα ανεξάρτητα του threshold

		Predicted	
		Healthy	mTBI
Actual	Healthy	TN True Negative Υγιής → Υγιής ✓	FP False Positive Υγιής → mTBI ✗
	mTBI	FN False Negative mTBI → Υγιής ✗	TP True Positive mTBI → mTBI ✓
			Σωστή πρόβλεψη
			Λανθασμένη πρόβλεψη

- $\tau_{pred} = 0.49$ καθορίστηκε με μεγιστοποίηση Youden's Index ($J = 0.453$) στη Φάση 1.

Αποτελέσματα

Απόδοση · Feature Importance · Σύγκριση

Απόδοση Μοντέλου

Μετρική	Phase 1 5-fold CV (n=48)	Phase 2 LOO (n=12)
Accuracy	0.726 ± 0.047	0.707 ± 0.133
Sensitivity	0.739 ± 0.075	0.688 ± 0.187
Specificity	0.713 ± 0.083	0.725 ± 0.191
AUC-ROC	0.792 ± 0.045	0.760 ± 0.141

Τιμές: $mean \pm std \cdot 100$ ανεξάρτητες επαναλήψεις


Φάση 1:

- Χαμηλές τυπικές αποκλίσεις → **σταθερή απόδοση** σε όλα τα *splits*
- $Sensitivity > Specificity$ → ελαφρώς καλύτερος εντοπισμός *mTBI*

Φάση 2:



- Μεγαλύτερες αποκλίσεις αναμενόμενες, αφού 1 λάθος = 8.3% μεταβολή στην απόδοση
- $Sensitivity < Specificity$ → πιο συντηρητικό σε *unseen data*
- $AUC\ Phase\ 1 \approx AUC\ Phase\ 2$ → **καλή γενίκευση**

Καμπύλη ROC — Φάση 2 (100 επαναλήψεις)



Feature Importance & Ποσοστό επιλογής ανά threshold

KAN Feature Stability: Importance Score & Selection Rate per Threshold



- **Temporal features** (TP , DT_2 , DT_1 , OT_1): διατηρούνται σχεδόν σε όλα τα thresholds
- **Graph-theoretic features**: εξαφανίζονται σχεδόν εξ ολοκλήρου πάνω από $\tau=0.1$
- TP : near-complete selection ακόμα και στο αυστηρότερο threshold $\rightarrow$ σταθερός και ισχυρός δείκτης


Feature Importance & Ποσοστό επιλογής

Τα temporal χαρακτηριστικά κυριαρχούν κι εδώ, ενώ τα graph-theoretic έχουν παρόμοιες τιμές μεταξύ τους.

Feature	% Επιλογής	Importance
TP	96.6%	0.57
DT ₂	81.2%	0.37
DT ₁	51.4%	0.19
OT ₁	31.6%	0.12
GE ₁	10%	0.10
CC ₁	4%	0.09
CPL ₁	6%	0.10
GE ₂	6.3%	0.10
CC ₂	5.7%	0.09
CPL ₂	6.5%	0.10

KAN Visualization

- *Opacity ακμής = feature importance*
- *TP: μη-μονότονη καμπύλη → συγκεκριμένα τμήματα περιέχουν περισσότερη πληροφορία*
- *DT₂: απότομη απόκριση σε συγκεκριμένες περιοχές → threshold-like συμπεριφορά*
- *Graph-theoretic features: σχεδόν γραμμικές συναρτήσεις*



Σύγκριση με Baseline Ταξινομητές

Ίδιο nested CV/LOO πρωτόκολλο: Radial Basis Function (RBF) kernel και Multi-Layer Perceptron (MLP) με ένα hidden layer.

Μοντέλο	Accuracy	AUC-ROC	Sensitivity	Specificity
KAN	0.707 ± 0.133	0.760 ± 0.141	0.688 ± 0.187	0.725 ± 0.191
SVM	0.746 ± 0.103	0.781 ± 0.121	0.715 ± 0.153	0.777 ± 0.150
MLP	0.758 ± 0.100	0.796 ± 0.123	0.740 ± 0.157	0.775 ± 0.152

- SVM & MLP ξεπερνούν KAN κατά ~4–5% σε accuracy → εντός της σταθερής διακύμανσης ~0.10–0.13
- SVM & MLP σχεδόν πανομοιότυπα → ceiling ~75–76% accuracy για αυτό το σύνολο χαρακτηριστικών
- SVM/MLP = black boxes | KAN = οπτικοποιήσιμη ϕ ανά feature → **κλινική διαφάνεια**
- Σε κλινικό περιβάλλον: το γιατί μια απόφαση λαμβάνεται είναι εξίσου σημαντικό με το τι αποφαινεται

Συζήτηση

Συμπεράσματα · Περιορισμοί · Μελλοντική Εργασία

Νευροφυσιολογική Ερμηνεία Αποτελεσμάτων

Κύρια Ευρήματα

- Υψηλό TP → συχνές μεταβάσεις → αστάθεια δικτυακής οργάνωσης
- Μειωμένο DT₂ → λιγότερος χρόνος στη χαμηλή συνδεσιμότητα → μειωμένη χρονική σταθερότητα

Νευροφυσιολογικός Μηχανισμός

- DAI → βλάβη white matter tracts → διαταραχή long-range συγχρονισμού
- Αποτέλεσμα: ο εγκέφαλος δεν μπορεί να διατηρήσει σταθερές καταστάσεις → ↑TP, ↓DT₂

Συνεισφορά KAN

- Ίδια χαρακτηριστικά με Antonakakis et al. (2020) ως κύριοι δείκτες
- Άμεσος εντοπισμός τους: το KAN τα απομονώνει μέσω του training
- Μη-γραμμικά splines: συγκεκριμένες περιοχές τιμών TP/DT₂ πιο πληροφοριακές → μη-ομοιόμορφη σχέση με την έξοδο

Περιορισμοί και Μελλοντική Έρευνα

- Μικρό μέγεθος dataset: $n=60$ μετά το balancing → αξιόπιστα αλλά όχι οριστικά αποτελέσματα
 - Μεγάλη διακύμανση Phase 2: 12 test subjects ανά run → 1 λάθος = 8.3% αλλαγή
 - Τυχαία υποδειγματοληψία: διαφορετική σύνθεση υγιών subjects ανά run
 - Feature selection variability: κανένα μεμονωμένο threshold δεν κυριαρχεί → αστάθεια λογικής σε κλινική εφαρμογή
 - Shallow αρχιτεκτονική: δεν μπορεί να ανιχνεύσει αλληλεπιδράσεις μεταξύ χαρακτηριστικών
- Validation σε μεγαλύτερο, ανεξάρτητο dataset → ισχυρότερα συμπεράσματα
 - Deeper KAN architecture με ένα hidden layer → ανίχνευση πολύπλοκων σχέσεων
 - Multi-band chronnectomics: συνδυασμός χαρακτηριστικών από πολλές ζώνες συχνότητας
 - Αν οι απεικονίσεις spline για τα συγκεκριμένα features επιβεβαιωθούν και από άλλα datasets → νευροφυσιολογικές μελέτες για κατανόηση μηχανισμών DAI

Ευχαριστώ για την προσοχή σας!

Ερωτήσεις;